

ACH2036 - Métodos Quantitativos para Análise Multivariada

Atividade 2: Aplicação de Modelos de Regressão Logística

1 Introdução

O objetivo desta atividade é a aplicação de Regressão Logística sobre um *problema de classificação binária*. Para isso, você poderá escolher uma base apropriada.

Seguem abaixo alguns exemplos de repositórios (mas você pode pesquisar em outros que conhecer):

- UCI Machine Learning Repository: <https://archive.ics.uci.edu/ml/index.php>
Este repositório é um dos mais conhecidos e possui um conjunto enorme de bases de dados.
- KDnuggets:
<http://www.kdnuggets.com/datasets>
<https://www.kdnuggets.com/2015/04/awesome-public-datasets-github.html>
- Ferramenta Google Dataset Search: <https://toolbox.google.com/datasetsearch>
- Kaggle: <https://www.kaggle.com/datasets>
- Microsoft Research Open Data: <https://msropendata.com>

Se tiver interesse em utilizar dados relacionados ao seu estágio/trabalho/iniciação científica, é perfeitamente possível – mas fica sob sua responsabilidade solicitar ao (à) seu(sua) superior(a) ou orientador(a) a autorização para uso desses dados. Isso é especialmente crítico se envolver dados pessoais de terceiros ou dados críticos da empresa.

2 Critérios para a escolha da base:

1. Naturalmente, a base deve possuir uma variável resposta binária.
2. A base deve conter pelo menos cinco variáveis preditoras. Se o número for muito maior do que isso (por exemplo, mais do que 10), algumas variáveis poderão ser eliminadas com a estratégia comentada mais adiante.

Se sua base de escolha não contém este número mínimo de variáveis mas tem uma motivação clara (p.ex. está sendo usada em algum projeto de pesquisa em que você participa ou tem relação com algum tema de seu interesse), *isso deverá ser justificado* (ver adiante).

3. Algumas bases contêm identificadores dos registros (código de paciente, código da amostra, etc). Eles até podem ser mantidos por você para facilitar eventual identificação de registros anômalos (com outliers, com dados faltantes etc), mas raramente são utilizados em análises estatísticas e não deverão ser utilizados como variáveis preditoras. Leve isso em consideração no item acima.
4. Idealmente, ao menos uma das variáveis preditoras deve seja categórica, para permitir a você explorar esse tipo de variável em seu modelo. Se não for possível utilizar uma base atendendo esta recomendação, *isso deverá ser justificado* (ou seja, por que razão a base escolhida era importante, mesmo não contendo variáveis categóricas).

3 Comentários sobre a análise exploratória e pré-processamento dos dados:

A análise exploratória dos dados (AED) é uma etapa importante e obrigatória, para a verificação da necessidade de eliminação de campos identificadores de registros, pré-processamento de variáveis categóricas e transformações de escala em variáveis numéricas.

Campos identificadores ou descritivos

Campos como código, nome, endereço etc. devem ser suprimidos na análise. Somente devem ser mantidas variáveis com as características potencialmente relevantes para a identificação de padrões.

Variáveis categóricas

A inspeção de variáveis categóricas também é importante, com especial atenção à eventual necessidade de tratamento de categorias equivalentes ou com frequências relativas muito baixas.

- No caso de categorias equivalentes para o propósito da análise estatística, pode ser conveniente sua fusão em uma só. Por exemplo, em bases de dados com descrições pessoais, uma variável usual é “Estado Civil”; nessas bases, é comum apresentar “Casado” e “União estável” como duas categorias distintas. Nesses casos, se esta distinção não for considerada relevante, pode ser mais conveniente agrupá-las em uma só (“Casado/União estável”). O mesmo vale para as categorias “Divorciado” e “Separado judicialmente”.
- No caso de categorias com frequências muito baixas (o que pode ser analisado através de tabelas de frequências ou gráficos de barras), há duas situações frequentes:
 - Categorias do tipo “Não informado”: nesses casos, pode-se considerar esta categoria como valor faltante. Nesta Atividade 1, não consideraremos o tratamento de valores faltantes, e os registros nesta situação poderão ser eliminados (a menos que sua proporção seja muito alta).

– Categorias informadas, porém com prevalência muito baixa na população. Se essas categorias não forem consideradas como equivalentes a outras mais frequentes, tipicamente seu tratamento deve ser discutido com os especialistas na área (manutenção da categoria ou eliminação dos respectivos registros). Para os propósitos desta Atividade 1, você terá liberdade de escolher uma dessas duas opções (*mas justifique*).

Variáveis numéricas

Entre os diversos tipos de análise para variáveis numéricas, consideramos aqui o aspecto de suas distribuições individuais e associações entre pares de variáveis.

A análise das distribuições individuais das variáveis pode ser feita de forma visual, através de histogramas ou *boxplots*, ou ainda com indicadores numéricos de assimetria (*skewness*) ou curtose. Para os propósitos desta Atividade 1, nossa principal preocupação é a assimetria – pois é uma das características com maior impacto negativo na análise de regressão logística.

Para análise gráfica, o notebook `Secao_7_ResidualDiagnostics.ipynb`, disponibilizado no diretório do Google Colab desta disciplina, contém a implementação de uma função para gerar uma *scatter plot matrix* adaptada, e que pode ser utilizada em seu trabalho.

Para variáveis com alta assimetria, pode ser necessário aplicar algum tipo de transformação. A Seção 9: **Data Transformations** do material de aula utilizado no tópico de Regressão Linear (<https://online.stat.psu.edu/stat501/lesson/9>) descreve várias situações e as respectivas transformações. Uma transformação interessante é a *transformação potência*, cuja formulação é a seguinte:

$$y^* = \begin{cases} y^\lambda, & \text{se } \lambda \neq 0, \\ \ln(y), & \text{se } \lambda = 0, \end{cases} \quad (1)$$

em que y é a variável original a ser transformada, y^* é a versão transformada e λ é o expoente utilizado como parâmetro. Um aspecto interessante dessa família é a generalização para vários casos específicos:

$$\begin{aligned} \lambda = -2 &\rightarrow y^* = \frac{1}{y^2} \\ \lambda = -1 &\rightarrow y^* = \frac{1}{y} \\ \lambda = -0.5 &\rightarrow y^* = \frac{1}{\sqrt{y}} \\ \lambda = 0 &\rightarrow y^* = \ln y \\ \lambda = 0.5 &\rightarrow y^* = \sqrt{y} \\ \lambda = 1 &\rightarrow y^* = y \text{ (identidade)} \\ \lambda = 2 &\rightarrow y^* = y^2 \end{aligned}$$

Para variáveis limitadas dentro do intervalo $(0, 1)$, uma possibilidade possível (mas não a única) é a transformação *logito* (já apresentada em aulas anteriores):

$$y^* = \log\left(\frac{y}{1-y}\right) = \log(y) - \log(1-y)$$

Atenção: Esta transformação só vale dentro do intervalo aberto $(0, 1)$. Se houver valores $y = 0$ ou $y = 1$, você deve “truncá-los” para ficarem dentro do intervalo aberto: $y = 0 \rightarrow y = \epsilon$ e $y = 1 \rightarrow y = 1 - \epsilon$, onde ϵ é uma constante pequena (p.ex. 10^{-3} ou 10^{-4}). Naturalmente, para variáveis descritas em percentuais (entre 0% e 100%), a adaptação é imediata, bastando dividi-las por 100 e aplicando a transformação acima.

4 Etapas da modelagem

As etapas da modelagem deverão seguir os seguintes passos:

1. **Análise exploratória dos dados:** discutida anteriormente.
2. **Separação do conjunto original em treino e teste:**

Você deve aplicar o procedimento *holdout*, sorteando 70% da base original para treinamento e os 30% restantes para teste.

Algumas funções implementadas para este procedimento permitem aplicar o *holdout estratificado*, no qual o sorteio das instâncias para treinamento e teste é feito separadamente para cada classe da variável alvo; isso garante que as proporções finais das classes nesses dois conjuntos se mantenha a mesma.

As próximas etapas intermediárias (seleção de variáveis, ajuste do modelo, calibração do limiar para $\pi(\mathbf{x})$) serão realizadas sobre o conjunto de treinamento. O conjunto de teste só será usado para a avaliação do modelo final.

3. **Seleção de variáveis:**

Minha recomendação é utilizar o procedimento *stepwise* descrito em <https://online.stat.psu.edu/stat501/lesson/10/10.2>, por ser simples e adaptável para regressão logística.

De toda forma, você tem liberdade para utilizar outra abordagem de seleção. Basta informar, em seu relatório, a abordagem utilizada e uma referência bibliográfica (ou link).

4. **Ajuste do modelo:**

Após as etapas anteriores, você deverá ajustar o modelo e apresentar os principais resultados desse ajuste (detalhes na próxima seção).

5. **Calibração do limiar para $\pi(\mathbf{x})$**

Uma vez ajustado o modelo, será necessário calibrar o limiar para $\pi(\mathbf{x})$. Para detalhes, ver os slides das aulas sobre Regressão Logística, tópico "Curva ROC". O notebook `RegLogistica_Titanic_03.ipynb` contém uma implementação em Python dessa calibração.

6. Avaliação do modelo final

A última etapa será avaliar o desempenho do modelo final sobre o conjunto de teste. A especificação dos resultados é apresentada na próxima seção.

5 Relatório:

Você deverá apresentar um pequeno relatório, com o título do trabalho e nomes dos integrantes do grupo (2 ou 3 integrantes, que podem ser de turmas distintas).

A estrutura de seções é a seguinte:

1. *Problema de classificação binária a ser tratado*

Inicie com um ou dois parágrafos com uma descrição geral sobre a base utilizada. Se tiver sido obtida de um repositório, explicitar o nome do repositório, nome da base e sua respectiva URL. Se for de outra origem, informar também.

Em seguida, apresente um breve enunciado do problema de classificação a ser resolvido. P.ex: *O objetivo original nesta base de dados é avaliar a associação entre a ocorrência de doença coronária e as características (idade, peso etc) ou hábitos (alimentação, sedentarismo, tabagismo, consumo de álcool etc) em um grupo de indivíduos.*

Opcionalmente, você pode complementar o texto explicando a importância do problema, ou por que ele motivou sua escolha.

2. *Descrição da base*

Apresente um dicionário com as descrições das principais variáveis. Idealmente, a descrição de cada variável deve conter:

- a) Abreviação da variável: Se os nomes originais dos campos forem muito longos, crie nomes curtos ou abreviações que permitam uma fácil identificação. Isso é importante para facilitar a leitura dos gráficos e interpretação dos resultados. Evite nomes codificados (V01, V02, etc). Se a base original já continha nomes curtos, você pode suprimir este campo, mantendo apenas seu nome original (campo abaixo).
- b) Nome original da variável.
- c) Breve descrição da variável.
- d) Tipo da variável – contínua/inteira/categórica ordinal/categórica não ordinal.

Nota: Por conveniência, em algumas bases é comum que as variáveis categóricas sejam codificadas em números (1,2, etc). Mas a natureza dessas variáveis permanece

categorica e elas não devem ser tratadas nas análises estatísticas como variáveis numéricas. Utilize os nomes das categorias (mesmo que abreviados) em vez dos códigos numéricos!

Se algumas variáveis necessitaram de algum tratamento de ajuste de escala, reagrupamentos de categorias e outras situações comentadas na Seção 3, detalhe esses casos.

3. Caracterização das principais variáveis após eventuais tratamentos

Nesta seção, você apresentará gráficos ou tabelas para visualização das distribuições das principais variáveis e das associações entre elas.

Observações:

- Para evitar que o relatório fique muito extenso, essas visualizações podem ser apresentadas somente sobre os dados pré-processados (conforme descrito na Seção 3).
- Se sua base original continha um número muito grande de variáveis, você pode apresentar os gráficos ou tabelas somente das variáveis selecionadas em seu modelo (ver item abaixo).

4. Seleção de variáveis

Descreva, em linhas gerais, o procedimento de seleção de variáveis utilizado. Mesmo que tenha adotado o procedimento *stepwise* descrito em <https://online.stat.psu.edu/stat501/lesson/10/10.2>, apresente uma síntese desse procedimento. O mesmo vale se tiver utilizado outra abordagem de seleção (neste caso, inclua também uma referência bibliográfica ou link sobre essa abordagem).

5. Resultados

Nesta seção, você apresentará os resultados da análise, *seguidos de seus comentários e interpretações em cada etapa*:

- Tabela dos coeficientes das variáveis selecionadas: além do valor estimado do coeficiente, apresentar intervalo de confiança OU o p-valor de algum teste de significância (teste da razão de verossimilhança ou teste de Wald). Para detalhes, ver slides das aulas, tópico "Teste de Significância dos Coeficientes".
- Matrizes de confusão dos modelos *sem* e *com* a calibração do limiar para $\pi(\mathbf{x})$, aplicados sobre o conjunto de teste.
- Uma tabela ou gráfico comparativo das principais métricas de desempenho dos modelos *sem* e *com* a calibração do limiar para $\pi(\mathbf{x})$, derivados das respectivas matrizes de confusão.

Um exemplo de tabela e gráfico comparativos é apresentado no notebook `RegLogistica_Titanic_03.ipynb`.

Comente as diferenças entre as métricas nesses dois modelos. Houve vantagens na calibração?

6. Comentários finais

Apresente seus comentários pessoais sobre a qualidade do modelo final – com a calibração do limiar de $\pi(\mathbf{x})$. Algumas questões relevantes são:

- O desempenho do modelo parece razoável à luz do problema original?
- As associações identificadas pelo modelo entre as variáveis preditoras e a variável alvo fazem sentido sob o ponto de vista do problema? Ou há indícios de algumas correlações espúrias?
- Quais outras variáveis faltantes na base poderiam melhorar a qualidade do modelo?

6 Formato e prazo para entrega

- A entrega deverá ser realizada em um documento PDF.
- O produto a ser entregue é um **relatório em PDF**, com a estrutura indicada na Seção 5. Não há necessidade de incluir o código Python.
- *Para quem preferir entregar seu relatório dentro de um Notebook Python com código e texto integrados*, isto também é possível – com as ressalvas abaixo.

- O notebook deve respeitar a estrutura especificada.
- A solução de “imprimir” o notebook em formato PDF não funciona direito, pois a versão PDF gerada não mantém a fidelidade do notebook (algumas figuras ficam “cortadas” e o texto se sobrepõe às figuras).
- Uma solução possível (já apresentada no enunciado da Entrega 1) é a seguinte:

Utilize o script `Conversao_ipynb_2_pdf.ipynb`, disponível no drive compartilhado da disciplina:

https://drive.google.com/drive/folders/19H5V3mnNc9KMnXke3m5YKGMbVNedGu41?usp=drive_link.

Fiz o teste desse script e, aparentemente, ele consegue gerar uma versão PDF com boa fidelidade visual em relação ao Notebook original. Mas recomendo testar o script sobre seu notebook e verificar se não há trechos de texto/figuras truncados ou omitidos.

- A entrega deverá ser feita exclusivamente através do e-disciplinas.
- **Prazo para entrega: 08/12 (não prorrogável).**