



UNIVERSIDADE DE SÃO PAULO
ESCOLA DE ARTES, CIÊNCIAS E HUMANIDADES

MÉTODOS QUANTITATIVOS PARA ANÁLISE MULTIVARIADA
DOCENTE: MARCELO LAURETTO

ATIVIDADE 2
RELATÓRIO DA APLICAÇÃO DE MODELOS DE REGRESSÃO LOGÍSTICA

Gustavo Pompermayer Fulanetti Silva
João Gabriel de Senna Lamolha

NºUSP 14760280
NºUSP 14777879

SÃO PAULO 2024

1. Introdução

Este relatório apresenta a Atividade 2 da disciplina ACH2036 - Métodos Quantitativos para Análise Multivariada (MQAM), focada na aplicação de um modelo de Regressão Logística para um problema de classificação binária. A base de dados utilizada provém do Sistema de Informação de Vigilância Epidemiológica da Gripe (SIVEP-Gripe), abrangendo notificações de Síndrome Respiratória Aguda Grave (SRAG). Ela pode ser encontrada no link: https://drive.google.com/drive/folders/1bd2aTVlpW1vnEPK1q61vxb_WefAMKnRU?usp=drive_link

O objetivo central do estudo é prever o risco de óbito (target = 1) em pacientes hospitalizados com SRAG, utilizando variáveis clínicas, demográficas e epidemiológicas. Diferentemente da regressão linear, que prevê valores contínuos, a regressão logística aqui empregada busca estimar a probabilidade de um evento crítico (óbito), permitindo identificar fatores de risco e apoiar a triagem médica.

Dada a natureza crítica do problema (vida ou morte), o estudo prioriza a métrica de Recall (Sensibilidade), visando minimizar a não detecção de casos graves, mesmo que isso implique em uma redução da precisão (mais falsos positivos).

2. Detalhes da Base

A base de dados original (*srag_data.csv*) continha mais de 264.000 registros e 195 colunas. Após um rigoroso processo de limpeza, tratamento de dados faltantes e filtragem de casos relevantes (focando apenas em evoluções de Cura ou Óbito), o dataset final (*df_clean.csv*) consolidou-se com 260.693 registros validados para a modelagem estatística.

O desbalanceamento das classes é um fator crítico: aproximadamente 92,4% dos casos resultaram em cura e apenas 7,6% em óbito. Isso exigiu estratégias específicas de modelagem para evitar vieses em direção à classe majoritária.

Variável Resposta (Dependente):

A. target - *Desfecho clínico*

- Origem: Derivada do campo original “*Evolução do caso*”
- Tipo: Categórica (Binária)
- Descrição: Variável dependente que indica o estado final do paciente. Assume valor 0 para Cura e 1 para Óbito por SRAG.

Variáveis Preditoras (Independentes):

B. NU_IDADE_N – *Idade do Paciente*

- Tipo: Numérica (Discreta).
- Descrição: Idade do paciente notificada em anos. É a principal variável demográfica associada ao risco linear de mortalidade.

C. faixa_refinada – *Faixas etárias*

- Origem: Derivadas da variável *NU_IDADE_N*
- Tipo: Categórica (Binária)
- Descrição: Faixas etárias escolhidas que podem indicar que os grupos possuem riscos distintos não explicados apenas pela idade linear

D. dias_entre_sintomas_e_internacao – *Tempo até Internação*

- Tipo: Numérica (Contínua).
- Origem: Foi calculada pela diferença entre a Data da internação por SRAG (*DT_INTERNA*) e a Data de 1ºs sintomas (*DT_SIN_PRI*).
- Descrição: Quantidade de dias decorridos entre o início dos primeiros sintomas e a data efetiva da internação hospitalar.

E. dias_entre_sintomas_e_uti – *Tempo até UTI*

- Tipo: Numérica (Contínua).
- Origem: Calculada pela diferença entre a Data da entrada na UTI (*DT_ENTUTI*) e a Data dos 1ºs sintomas (*DT_SIN_PRI*).
- Descrição: Quantidade de dias decorridos entre o início dos primeiros sintomas e a transferência do paciente para a Unidade de Terapia Intensiva.

F. SATURACAO – *Saturação de Oxigênio*

- Tipo: Categórica (Binária).
- Descrição: Indica se o paciente apresentou saturação de oxigênio abaixo de 95% (1 = Sim, 0 = Não).

G. DISPNEIA – *Dificuldade Respiratória*

- Tipo: Categórica (Binária).
- Descrição: Presença (1) ou ausência (0) de dispneia (falta de ar) no momento da notificação.

H. DESC_RESP – *Desconforto Respiratório*

- Tipo: Categórica (Binária).
- Descrição: Indica se o paciente apresentava (1) ou não (0) desconforto respiratório.

I. UTI – *Internação em UTI*

- Tipo: Categórica (Binária).
- Descrição: Indica se o paciente foi internado (1) ou não (0) na UTI.

J. HOSPITAL – *Internação*

- Tipo: Categórica (Binária).
- Descrição: Indica se o paciente foi internado (1) ou não (0).

K. SUPORT_VEN – *Suporte Ventilatório*

- Tipo: Categórica (Nominal).
- Descrição: Indica se o paciente necessitou de suporte ventilatório e qual o tipo: invasivo (*SUPPORT_VEN1*), não invasivo (*SUPPORT_VEN2*), não utilizou (*SUPPORT_VEN3*) e não respondido (*SUPPORT_VEN9*). No modelo, foi tratada via One-Hot Encoding.
- Nota: A categoria *SUPPORT_VEN1* (Invasivo) é a referência basal para comparação de risco. A categoria *SUPPORT_VEN9* (Não respondido) foi mantida como controle de dados faltantes, permitindo aproveitar os registros desses pacientes.

L. TOSSE - *Tosse*

- Tipo: Categórica (Binária).
- Descrição: Indica se o paciente apresentou (1) ou não (0) sintomas de tosse.

M. NEUROLOGIC - *Doença neurológica*

- Tipo: Categórica (Binária).

- Descrição: Indica se o paciente apresentou (1) ou não (0) sintomas de tosse.

N. ASMA - *Asma*

- Tipo: Categórica (Binária).
- Descrição: Indica se o paciente possui (1) ou não (0) asma.

O. RES_AN – *Resultado do Teste Antigênico*

- Tipo: Categórica (Binária).
- Descrição: Variáveis *RES_AN_2.0* e *RES_AN_5.0* indicam, respectivamente, resultado negativo ou pendente no teste rápido.


P. PUERPERA – *Se paciente pariu recentemente*

- Tipo: Categórica (Binária).
- Descrição: Variáveis *PUERPERA_2* e *PUERPERA_9* indicam, respectivamente, que a paciente não pariu ou que não houve resposta(nulo).

3. Caracterização das principais variáveis após eventuais tratamentos

Nesta etapa, realizou-se a inspeção visual e estatística das variáveis processadas no dataset final, com foco na distribuição da variável resposta, comportamento dos preditores numéricos e correlações entre os sintomas clínicos.

3.1. Distribuição da Variável Resposta (Desbalanceamento)



A análise da variável alvo (target) revelou um desbalanceamento severo, característica típica de bases de dados epidemiológicas de SRAG, onde a maioria dos casos notificados evolui para a cura.


- Classe 0 (Cura): Representa a classe majoritária.
- Classe 1 (Óbito): Representa a classe minoritária (evento raro).

Este desbalanceamento guiou a estratégia de modelagem subsequente, priorizando métricas de sensibilidade (*Recall*) em detrimento da acurácia global, visto que o custo de não detectar um óbito (Falso Negativo) é clinicamente inaceitável.

3.2. Análise das Variáveis Numéricas (Idade e Tempo)


As variáveis quantitativas mantidas no modelo apresentaram comportamentos distintos quanto à sua distribuição e relação com o desfecho:

1. Idade (*NU_IDADE_N*):



- Ao analisar a distribuição de idade por desfecho observa-se uma clara distinção nas medianas. A linha central do grupo Óbito (1) situa-se em uma faixa etária significativamente superior à do grupo Cura (0).
- Interpretação: A "caixa" do grupo de óbitos concentra-se na parte superior do eixo Y, indicando que a mortalidade é predominante em pacientes idosos. Em contrapartida, o grupo de cura apresenta uma dispersão muito maior, abrangendo desde crianças até adultos jovens. Isso justifica a forte influência da idade como preditor de risco.

2. Variáveis Temporais (*dias_entre_sintomas_e_internacao/uti*):




Ambas as variáveis apresentaram distribuição assimétrica positiva (cauda longa à direita), com concentração maior nos primeiros dias. Valores próximos a zero indicam atendimento imediato ou gravidade fulminante, enquanto a cauda longa sugere demora na busca por socorro.

Nota: Valores negativos, indicativos de casos nosocomiais (início dos sintomas após internação), foram desconsiderados nesta visualização gráfica para focar no fluxo de entrada comunitária.

Comparando os gráficos, nota-se que a curva de admissão na UTI (Gráfico B) apresenta um leve achatamento e dispersão maior que a da internação geral, refletindo o intervalo de tempo necessário para o agravamento clínico do paciente após a chegada ao hospital.

3.3. Associações entre Variáveis Categóricas



As variáveis categóricas apresentaram associações relevantes entre si, mapeadas através da matriz de correlação (Heatmap).

- Redundância entre Sintomas (Multicolinearidade): Observou-se correlação positiva entre *DISPNEIA*, *DESC_RESP* e *SATURACAO*. Isso indica um padrão clínico: pacientes que apresentam um destes sinais frequentemente manifestam os demais simultaneamente. Da mesma forma, a variável *UTI* possui forte ligação com *SUPORT_VEN* (Ventilação).
- Associação com o Desfecho (Target): A variável *UTI* apresentou correlação positiva com a variável *target*. Estatisticamente, isso confirma que a admissão em terapia intensiva é o indicador mais forte de gravidade clínica na base de dados: pacientes admitidos na *UTI* pertencem ao grupo de maior risco de óbito devido à severidade de seu quadro inicial.

A presença dessas correlações entre preditores reforçou a necessidade de adotar, na etapa de modelagem (Seção 4), uma estratégia de seleção de variáveis capaz de lidar com a redundância das informações.

4. Seleção de Variáveis

Dada a alta dimensionalidade da base de dados original (contendo mais de 100 colunas após a codificação das variáveis categóricas) e a presença de forte multicolinearidade entre os sintomas clínicos (conforme demonstrado na Seção 3.3), optou-se por não utilizar métodos iterativos clássicos, como o *Stepwise Backward*. Embora populares, métodos *Stepwise* podem ser instáveis e propensos a *overfitting* em cenários com muitas variáveis correlacionadas.

Em substituição, adotou-se a estratégia de Regularização L1 (Lasso) integrada ao modelo de Regressão Logística.

4.1 Descrição do Método (Lasso)

O método Lasso (Least Absolute Shrinkage and Selection Operator) modifica a função de custo da Regressão Logística adicionando um termo de penalidade proporcional à soma dos valores absolutos dos coeficientes (β). Matematicamente, o algoritmo busca minimizar a seguinte função:

$$\text{Custo} = -\ln(L) + \lambda \sum_{j=1}^P |\beta_j|$$

Onde:

- $-\ln(L)$ é a log-verossimilhança (ajuste aos dados).
- λ é o parâmetro de regularização (intensidade da penalidade).

A principal propriedade geométrica da penalização L1 é sua capacidade de forçar os coeficientes de variáveis pouco informativas ou redundantes a se tornarem exatamente zero. Isso faz com que o Lasso funcione não apenas como um algoritmo de classificação, mas como um método robusto e automático de seleção de *features*.

4.2. Procedimento Aplicado

O procedimento de seleção seguiu as seguintes etapas computacionais:

- Pré-processamento:** Padronização das variáveis numéricas e codificação (*One-Hot Encoding*) das categóricas.
- Ajuste Inicial com Penalidade:**

```

pipe = Pipeline([
    ('scaler', StandardScaler()),
    ('clf', LogisticRegression(
        penalty='l1',
        class_weight='balanced',
        solver='saga',
        C=1.0,
        max_iter=5000,
        random_state=SEED
    ))
])

```

Treinou-se um estimador de Regressão Logística utilizando o solver *saga* (otimizado para grandes *datasets*) e penalidade l1.

c. **Filtragem (*SelectFromModel*):**

```

# 2. Seleção das features
selector = SelectFromModel(pipe.named_steps['clf'], prefit=True, threshold="mean")
selected = selector.get_support()
selected_features = X_train.columns[selected]

```

O algoritmo identificou e descartou automaticamente todas as variáveis cujos coeficientes foram zerados pelo processo de otimização.

- d. **Seleção Final:** Apenas as variáveis com coeficientes não nulos (listadas na Seção 2) foram mantidas para o treinamento do modelo final, garantindo um conjunto de preditores mais enxuto e interpretável, livre de ruído estatístico.

Bibliografia para o Lasso

TIBSHIRANI, Robert. *Regression Shrinkage and Selection via the Lasso*. Journal of the Royal Statistical Society. Series B (Methodological), v. 58, n. 1, p. 267–288, 1996. Disponível em: [https://webdoc.agsci.colostate.edu/koontz/arec-econ535/papers/Tibshirani%20\(JRSS-B%201996\).pdf](https://webdoc.agsci.colostate.edu/koontz/arec-econ535/papers/Tibshirani%20(JRSS-B%201996).pdf)

Documentação Scikit-Learn: *L1-based feature selection*. Disponível em: https://scikit-learn.org/stable/modules/feature_selection.html#l1-based-feature-selection.

5. Resultados

Nesta seção, apresentamos o desempenho do modelo de Regressão Logística ajustado com as variáveis selecionadas na etapa anterior. A avaliação foi realizada sobre o conjunto de teste (30% da base, *holdout*), garantindo que as

métricas reflitam a capacidade de generalização do modelo para novos pacientes.

5.1. Importância dos Preditores e Significância Estatística

A análise dos coeficientes do modelo de Regressão Logística permite interpretar a direção e a magnitude da associação entre as variáveis clínicas e o desfecho de óbito. Para validar a robustez dessas associações, utilizou-se o teste de Wald (via biblioteca statsmodels), calculando-se o erro padrão e o p-valor para cada preditor selecionado pelo método Lasso.

Tabela de Coeficientes e Significância

A tabela abaixo resume os resultados estatísticos para as variáveis mais relevantes do modelo final:

Variável	Coeficiente	Erro médio	P-valor	Relação
const	-2.3184	0.2614	< 0.001	Intercepto (Valor Basal)
NU_IDADE_N	0.0368	0.0007	< 0.001	Relação Positiva (+)
TOSSE	-0.5420	0.0231	< 0.001	Relação Negativa (-)
DISPNEIA	0.3209	0.0289	< 0.001	Relação Positiva (+)
DESC_RESP	0.2889	0.0265	< 0.001	Relação Positiva (+)
SATURACAO	0.1896	0.0255	< 0.001	Relação Positiva (+)
ASMA	-0.5373	0.0499	< 0.001	Relação Negativa (-)

NEUROLOGIC	0.4645	0.0378	< 0.001	Relação Positiva (+)
HOSPITAL	-1.2734	0.0517	< 0.001	Relação Negativa (-)
UTI	0.3494	0.0308	< 0.001	Relação Positiva (+)
PUERPERA_2	0.8520	0.2496	0.0006	Relação Positiva (+)
PUERPERA_9	0.6880	0.2496	0.0058	Relação Positiva (+)
SUPPORT_VEN _2	-1.9445	0.0279	< 0.001	Relação Negativa (-)
SUPPORT_VEN _3	-2.5058	0.0378	< 0.001	Relação Negativa (-)
SUPPORT_VEN _9	-1.7891	0.0426	< 0.001	Relação Negativa (-)
RES_AN_2.0	-0.2749	0.0262	< 0.001	Relação Negativa (-)
RES_AN_5.0	-0.2999	0.0267	< 0.001	Relação Negativa (-)
dias_entre_sin tomas_e_inter nacao	-0.0117	0.0027	< 0.001	Relação Negativa (-)
dias_entre_sin	0.0366	0.0035	< 0.001	Relação Positiva (+)

tomas_e_uti				
faixa_refinada_2_4	-0.3990	0.0720	< 0.001	Relação Negativa (-)
faixa_refinada_5_17	-0.4417	0.0642	< 0.001	Relação Negativa (-)
faixa_refinada_18_39	0.4134	0.0534	< 0.001	Relação Positiva (+)
faixa_refinada_40_59	0.3451	0.0335	< 0.001	Relação Positiva (+)

Análise da Significância Estatística (P-Valor)

Observa-se que a vasta maioria das variáveis apresentou p-valor inferior a 0.001 (virtualmente zero). Este comportamento é esperado dada a magnitude da base de dados (N > 200.000 registros). Com um tamanho amostral tão expressivo, o teste de Wald torna-se extremamente sensível, conferindo significância estatística mesmo a pequenas associações.


A exceção notável foi o grupo de variáveis relacionadas ao puerpério (*PUERPERA*), que apresentou p-valores na ordem de 10^3 e 10^{-4} . Embora ainda estatisticamente significativos ($p < 0.05$), estes valores maiores refletem a menor prevalência (suporte) dessa condição específica na amostra em comparação aos sintomas gerais.

Interpretação Clínica dos Coeficientes

Os sinais dos coeficientes revelam a natureza da influência de cada variável:

1. Fatores de Risco (Coeficientes Positivos):

- **Idade e Comorbidades:** A variável *NU_IDADE_N* e comorbidades como *NEUROLOGIC* apresentaram coeficientes positivos, confirmando que o envelhecimento e doenças pré-existentes aumentam a probabilidade de desfecho fatal (target = 1).
- **Faixas etárias (Ajuste de Não-Linearidade):**



Complementando a idade numérica, a inclusão das faixas etárias revelou um comportamento não-linear crucial. Observou-se que a faixa 18-39 anos apresentou um coeficiente de risco positivo expressivo, indicando que o modelo linear tende a subestimar a gravidade neste grupo. Estatisticamente, essa variável atua como uma "correção para cima" na curva de risco. Hipóteses para esse comportamento incluem a maior exposição deste grupo (maior mobilidade) ou reações imunológicas agudas que fogem ao padrão do envelhecimento natural.


- **Gravidade Clínica:** As variáveis *UTI*, *DISPNEIA* e *SATURACAO* atuam como fortes marcadores de gravidade. A admissão em *UTI*, por exemplo, eleva o log-odds do óbito, indicando que pacientes que necessitam desse recurso já se encontram em estado crítico.

2. Fatores de "Proteção" (Coeficientes Negativos):

- **Ausência de Intervenção Invasiva:** A variável *SUPPORT_VEN_2* (Suporte Não Invasivo) possui um coeficiente fortemente negativo (-1.94). Como a categoria de referência implícita no modelo é o "Suporte Invasivo" (intubação), este resultado indica que pacientes que conseguem ser mantidos apenas com oxigenoterapia não invasiva têm chances de sobrevivência drasticamente superiores aos que necessitam de intubação orotraqueal.
- **Tosse:** Curiosamente, a presença de *TOSSE* apresentou associação negativa com o óbito. Clinicamente, isso pode sugerir que pacientes capazes de apresentar reflexo de tosse possuem melhor resposta

imunológica ou quadros menos fulminantes do que aqueles com "hipóxia silenciosa" ou rebaixamento de consciência.

5.2 Matrizes de confusão dos modelos sem e com a calibração do limiar para $\pi(x)$, aplicados sobre o conjunto de teste.




Análise Comparativa das Matrizes de Confusão:

As figuras acima ilustram o impacto drástico da calibração do limiar de decisão:

1. Modelo Padrão (Azul - Limiar 0.5):
 - Mostrou-se extremamente conservador e perigoso para triagem clínica.
 - Falhou em identificar 4.159 pacientes que vieram a óbito (Falsos Negativos - Canto Inferior Esquerdo), detectando corretamente apenas 1.600 casos. Isso representa uma perda inaceitável de sensibilidade.
2. Modelo Calibrado (Verde - Limiar Ajustado):
 - Ao reduzir o limiar, o modelo priorizou a detecção de risco.
 - Ganho de Sensibilidade: O número de óbitos detectados saltou para 5.534 (Canto Inferior Direito), restando apenas 285 casos não identificados. O modelo passou a cobrir a vasta maioria dos eventos críticos.
 - Custo em Especificidade: Como consequência esperada, o número de Falsos Positivos (alarmes falsos) subiu de 1.095 para 25.285 (Canto Superior Direito).
 - Justificativa: Clinicamente, este *trade-off* é vantajoso. É preferível alertar 25 mil pacientes que acabaram sobrevivendo

(encaminhando-os para observação) do que negligenciar os quase 4 mil pacientes graves que o modelo padrão ignoraria.



Análise das Métricas de Desempenho (Gráfico de Barras):

O gráfico comparativo acima quantifica a troca estratégica realizada pela calibração:

- Aumento expressivo do Recall (Sensibilidade): Observa-se que a barra correspondente ao Recall saltou de um patamar insatisfatório ($< 30\%$) no modelo padrão para acima de 95% no modelo calibrado. Isso comprova estatisticamente que o modelo agora recupera quase a totalidade dos eventos de interesse.
- Queda na Precisão: A barra de precisão sofreu redução (reflexo do aumento de Falsos Positivos). Contudo, em epidemiologia e triagem de emergência, uma precisão baixa é aceitável desde que a sensibilidade seja máxima.
- Acurácia enganosa: Nota-se que a Acurácia (barra amarela) caiu no modelo calibrado. Isso reforça que, em bases desbalanceadas, a Acurácia não é uma boa métrica para avaliar a segurança do modelo, pois o modelo padrão tinha "boa acurácia" apenas porque previa "Cura" para quase todo mundo, ignorando os óbitos.

Conclusão: A calibração transformou o modelo de uma ferramenta estatística precisa, porém insensível, em um instrumento de triagem seguro.

6. Comentários finais e conclusão

O presente estudo aplicou a Regressão Logística para a previsão de óbitos por SRAG, com foco na maximização da sensibilidade para fins de triagem clínica. Abaixo, discutimos os resultados à luz das questões propostas no enunciado.

6.1. Razoabilidade do Desempenho (Custo do Erro)

Pergunta: O desempenho do modelo parece razoável à luz do problema original?

Sim, o desempenho é considerado razoável e adequado para a função de triagem inicial, devendo ser avaliado sob a ótica do "Custo do Erro" em saúde pública:

- **Prioridade Clínica:** O problema original (SRAG) envolve risco iminente de vida. Neste contexto, o "custo" de um Falso Negativo (deixar um paciente grave sem assistência e ele vir a falecer) é infinitamente superior ao custo de um Falso Positivo (monitorar um paciente que não agravará).
- **Rede de Segurança:** Após a calibração do limiar, o modelo atingiu um Recall (Sensibilidade) superior a 95%. Isso significa que ele cumpre sua função primária de "rede de segurança", garantindo que a vasta maioria dos casos fatais seja detectada precocemente.
- **Justificativa da Baixa Precisão:** A baixa precisão (~18%) é uma limitação aceitável. O modelo extrai o máximo de sinal possível de dados baseados em sintomas gerais, alertando as equipes médicas para *todos* os casos potenciais e delegando a decisão final (mais específica) para a avaliação clínica presencial.

6.2. Sentido Clínico das Associações e Correlações

Pergunta: As associações fazem sentido ou há correlações espúrias?

As variáveis selecionadas pelo método Lasso demonstraram alta coerência com a fisiopatologia da SRAG, indicando que o modelo capturou relações causais reais:

- **Fatores de Risco (Coerentes):** As variáveis com maiores coeficientes positivos (Idade, admissão em UTI, Dispneia e queda de Saturação) são amplamente reconhecidas na literatura médica como marcadores diretos de gravidade e falência orgânica.
- **Ajuste de Não-Linearidade (Jovens Adultos):** A associação de risco encontrada na faixa etária 18-39 anos não é espúria, mas sim um

refinamento estatístico. O modelo identificou que a simples regressão linear da idade subestimava o risco neste grupo, possivelmente devido à maior exposição (mobilidade) ou respostas inflamatórias agudas.

- Investigação de Correlação "Protetora" (Tosse): A variável Tosse apresentou coeficiente negativo (fator de proteção), o que poderia parecer uma correlação espúria à primeira vista. Contudo, clinicamente, isso faz sentido: a presença de tosse exige reflexo neurológico preservado e vias aéreas pervias. A *ausência* de tosse em pacientes graves está frequentemente ligada ao rebaixamento de consciência ou hipóxia silenciosa, condições de maior letalidade. Portanto, o modelo interpretou corretamente um sinal clínico sutil.

6.3. Limitações e Variáveis Faltantes

Pergunta: Quais outras variáveis faltantes na base poderiam melhorar a qualidade do modelo?

A principal limitação para aumentar a precisão do modelo é a natureza dos dados atuais: majoritariamente variáveis categóricas binárias baseadas em sintomas subjetivos (apenas "Sim/Não"). Para um algoritmo de classificação, esses dados oferecem baixa resolução, dificultando a distinção matemática entre casos moderados e graves.

A qualidade do modelo seria significativamente ampliada com a inclusão de variáveis numéricas contínuas (Exames Laboratoriais), que trazem maior granularidade de informação. A literatura médica sugere o enriquecimento da base com biomarcadores quantitativos como:

- Dímero-D e Ferritina: Indicadores numéricos de coagulação e inflamação.
- Lactato e PCR: Métricas precisas de estresse metabólico e infecção.

Conclusão: Ao substituir *inputs* binários por dados contínuos, o algoritmo poderia traçar fronteiras de decisão (hiperplanos) muito mais refinadas, reduzindo a taxa de Falsos Positivos e aumentando a confiabilidade da triagem.